

Proyecto 4: Clasificación de señales ECG

Luisa F. Enciso¹ y Jader S. Chingal¹.

¹Universidad De Antioquia Facultad De Ingeniería, Bioingeniería, Bioseñales

luisa.enciso@udea.edu.co
jstalyn.chingal@udea.edu.co

I. CONTEXTUALIZACIÓN

Este proyecto se centra en el análisis automatizado de señales electrocardiográficas (ECG) para clasificar dos condiciones cardíacas principales: bradicardia sinusal (SB) y fibrilación auricular (AFIB). La motivación principal radica en la creciente necesidad de herramientas tecnológicas que apoyen a los especialistas en la detección precisa y oportuna de estas alteraciones, dada su relevancia en la práctica clínica y su impacto en la calidad de vida de los pacientes. La implementación de sistemas basados en machine learning tiene el potencial de optimizar la identificación de estas condiciones, reduciendo la carga de trabajo manual y minimizando posibles errores humanos.

El análisis inicial se fundamentó en la extracción de características relevantes de las señales de ECG, procesando un total de 5664 registros válidos después de descartar aquellos que no cumplieran con los criterios mínimos de calidad, como la detección de picos R o la longitud adecuada de la señal. Las características extraídas incluyen tasas ventriculares y auriculares, intervalos R-R, conteos de fases sistólicas y diastólicas, y otros parámetros derivados, como el fMP. Estas métricas se integraron en un conjunto de datos estructurado que sirvió como base para el entrenamiento y validación de los modelos propuestos.

La arquitectura principal del sistema empleó redes neuronales de perceptrón multicapa (MLP) bajo configuraciones diversas, incluyendo capas ocultas con 145, 72 y 48 neuronas. Tras un riguroso proceso de validación cruzada con 10 folds, se observó que la arquitectura de 145 neuronas obtuvo un desempeño ligeramente superior, alcanzando una precisión promedio de 0.9511. Los modelos se evaluaron utilizando métricas estándar como precisión, sensibilidad, especificidad y el análisis de las matrices de confusión para los conjuntos de entrenamiento y prueba. A pesar de las diferencias en el número de neuronas, todas las arquitecturas demostraron un alto desempeño, reflejado en precisiones globales superiores al 95%.

Además de las redes neuronales, se exploraron otros algoritmos de machine learning, como K-means y máquinas de soporte vectorial (SVM), para evaluar la efectividad de enfoques alternativos en la clasificación de las señales de ECG.

II. REVISIÓN TEÓRICA

El proceso de extracción de características se centra en el diseño de un método novedoso que sea interpretable y permita una clasificación robusta y precisa de las arritmias a partir de datos de ECG de 12 derivaciones. Aquí se describen los puntos clave: primero se analizan varias características morfológicas de las ondas y segmentos del ECG, tales como la altura, el ancho y la prominencia de picos y valles. Estas medidas se aplican a tres subconjuntos: los complejos QRS, los picos no-QRS y los valles. La prominencia, que indica cuán destacado es un pico o un valle respecto a su entorno, resulta particularmente útil, ya que resalta detalles clave de la morfología de las ondas. Estas características son fundamentales para identificar posibles anomalías asociadas a arritmias.

Además, se calculan distribuciones empíricas mediante tablas de frecuencia que muestran las relaciones entre los diferentes atributos, como las proporciones entre las diferencias de altura y los tiempos en combinaciones de picos y valles. Esta representación estadística agrega robustez al análisis, mejorando su capacidad para adaptarse a las variabilidades individuales que puedan presentarse en las señales.

También se incluye el cálculo del intervalo RR (tiempo entre picos R consecutivos), así como su media, varianza y conteo. Estas métricas son fundamentales para detectar irregularidades en los ritmos cardíacos, como en la fibrilación auricular, donde los intervalos RR son altamente variables.

Por último, se escalan los datos para unificar las amplitudes, lo que ayuda a reducir la influencia de diferencias individuales en la amplitud del ECG, como las que pueden estar asociadas al género, la edad o condiciones específicas. Además, se evaluaron diversas configuraciones de características, desde las más simples, que incluyen 11 variables básicas, hasta las más complejas, con hasta 39,830 variables que incorporan distribuciones empíricas. Este enfoque permite identificar las combinaciones óptimas de características, maximizando a sí la clasificación de arritmias, superando los desafíos inherentes a la variabilidad morfológica y las distorsiones causadas por diversas condiciones médicas.

Para discutir la función de la extracción de características en el contexto de enfermedades que provocan la desaparición de ciertas formas de onda en el complejo PQRS, tomamos como ejemplo la fibrilación auricular (AFIB). En esta condición, las ondas P suelen estar ausentes y son reemplazadas por ondas de fibrilación, caracterizadas por una ondulación irregular de baja amplitud. Estas ondas no están asociadas a los complejos QRS, los cuales aparecen de manera irregular. Ante esta ausencia de ondas P, el método de extracción de características se enfoca en la variabilidad de los intervalos RR, que corresponde al tiempo entre los picos R consecutivos, y en el análisis de las frecuencias resultantes de las transformaciones de las ondas presentes. Este enfoque permite clasificar ritmos irregulares incluso cuando las ondas P no están claramente definidas.

Por otro lado, en enfermedades como la isquemia miocárdica, la onda T puede desaparecer, invertirse o combinarse con cambios en el segmento ST, como elevación o depresión. Para identificar estos patrones, se analizan parámetros derivados del segmento ST-T, como su inclinación y duración. Además, se emplean técnicas de distribución empírica para detectar patrones de desviación asociados a estas condiciones, lo que facilita la identificación de anomalías en la señal ECG incluso cuando ciertos componentes están ausentes o alterados.[1]

III. SELECCIÓN DE DATOS

Se decidió seleccionar los datos del proyecto 2 debido a que, al analizar los resultados del proyecto 3, se identificó que la señal procesada no se ajustaba completamente a la señal prefiltrada empleada en el proyecto 2. Este hallazgo sugiere que el flujo de procesamiento utilizado en el proyecto 3 no logró una limpieza óptima de la señal, lo cual impactó negativamente en la calidad de los datos obtenidos.

Con el objetivo de minimizar el impacto del ruido y garantizar resultados más consistentes y confiables, se optó por trabajar con los datos del proyecto 2. En este contexto, se utilizó la frecuencia de máxima potencia, calculada mediante la transformada rápida de Fourier (FFT), como métrica para el análisis posterior.

IV. APLICACIÓN NEUROKIT

NeuroKit es una librería de Python de código abierto diseñada específicamente para el procesamiento de señales fisiológicas. Esta herramienta se ha convertido en un recurso invaluable para investigadores, científicos de datos y profesionales de la salud que trabajan con datos biológicos.

NeuroKit cuenta con una serie de funcionalidades que la posicionan como una herramienta altamente competitiva en el análisis de señales fisiológicas. Permite el filtrado y normalización de señales como ECG, EMG, EOG y EEG, facilitando la eliminación de artefactos y ruido.

Asimismo, permite la extracción de diferentes características basadas en la identificación de eventos específicos en las señales, como latidos cardíacos, picos respiratorios o actividad muscular. También ofrece el cálculo de métricas importantes como la frecuencia cardíaca (HR), la variabilidad de la frecuencia cardíaca (HRV), la actividad galvánica de la piel (GSR), entre otras. Además, posibilita el uso de transformadas y análisis en el dominio del tiempo, frecuencia y tiempo-frecuencia. Un aspecto destacado es su capacidad para generar gráficos intuitivos que permiten inspeccionar y analizar señales de manera visual, comparando una señal cruda con su versión procesada.

En el contexto de esta investigación, inicialmente se emplea la función `ecg_process()`, que no solo permite el procesamiento integral de las señales de ECG, sino que también calcula características relacionadas con la variabilidad de la frecuencia cardíaca (HRV).

Posteriormente, se lleva a cabo la visualización tanto de las señales de ECG como de las características extraídas, utilizando la función `ecg_plot()`. A continuación, se realiza la detección de picos R en la señal mediante la función `ecg_peaks()`. Finalmente, se desarrolla un análisis en el dominio del tiempo para evaluar la variabilidad de la frecuencia cardíaca (HRV), proporcionando una visión detallada de los parámetros fisiológicos extraídos.

Este minitutorial se aplica a seis señales, tres provenientes de sujetos con Bradicardia Sinusal (SB) y tres con Fibrilación Auricular (AFIB), obteniendo los siguientes resultados:

A. Sujetos con patología SB

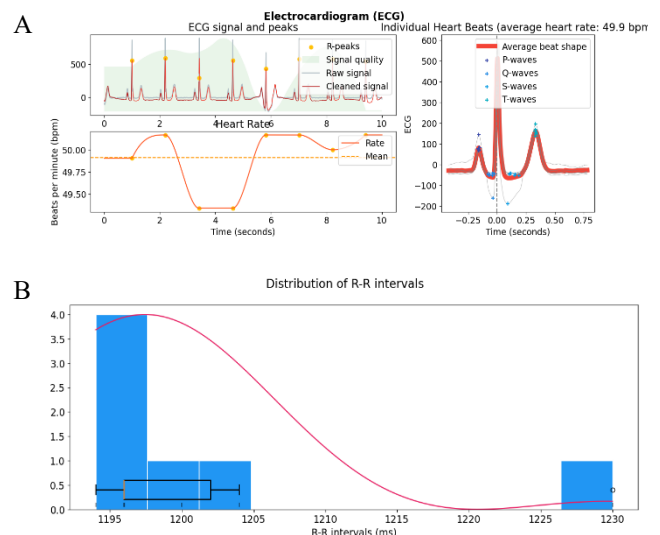


Figura 1: Resultados del minitutorial para el sujeto MUSE_20180116_130648_60000

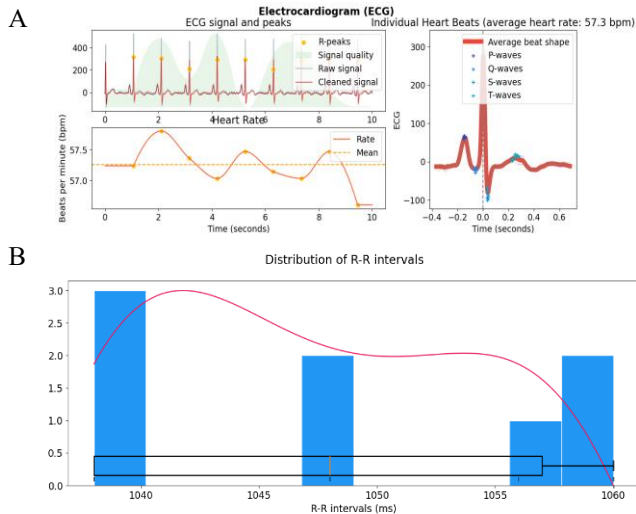


Figura 2: Resultados del minitutorial para el sujeto
MUSE_20180115_133308_88000

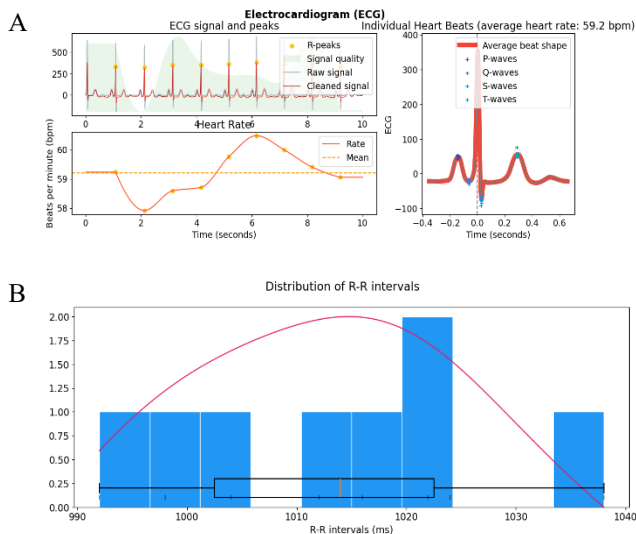


Figura 3: Resultados del minitutorial para el sujeto
MUSE_20180119_175736_85000

En las Figuras 1, 2 y 3, en la sección A, se observa en el panel superior izquierdo la señal cruda, que representa la actividad eléctrica del corazón tal como se registra originalmente. En esta señal se identifican claramente las ondas P, QRS y T, correspondientes a las distintas fases del ciclo cardíaco.

A continuación, se muestra la señal limpia, que ha sido procesada para eliminar ruido y artefactos, permitiendo una detección precisa de los picos R. Estos picos, conocidos como R-Peaks, marcan el inicio de los complejos QRS y son esenciales para calcular la frecuencia cardíaca y los intervalos R-R. El valor promedio de latidos por minuto en este caso indica bradicardia sinusal, una condición caracterizada por

una frecuencia cardíaca en reposo inferior a 60 latidos por minuto.

En el panel superior derecho, se presenta la forma promedio de un complejo QRS. Esta representación facilita la identificación de posibles anomalías en la morfología de la onda. En el caso analizado de la figura 2 y 3, la forma de onda parece ser normal, lo que sugiere que la bradicardia sinusal es primaria y no está asociada a una alteración estructural del corazón. Caso contrario, con el caso de la figura 1, dado que no se logra visualizar el pico S del complejo.

En la sección B de estas mismas figuras, se visualiza un histograma que muestra la frecuencia con la que se observan diferentes valores de intervalo R-R, reflejando la variabilidad de la frecuencia cardíaca. La curva superpuesta al histograma representa una estimación de la densidad de probabilidad de los intervalos R-R, proporcionando información detallada sobre la distribución de estos valores.

B. Sujetos con patología AFIB

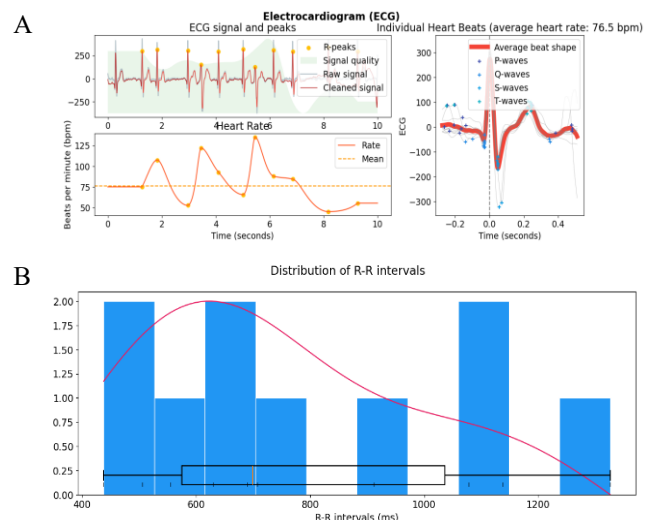



Figura 4: Resultados del minitutorial para el sujeto
MUSE_20180116_123051_48000






Figura 5: Resultados del minitutorial para el sujeto MUSE_20180113_171327_27000

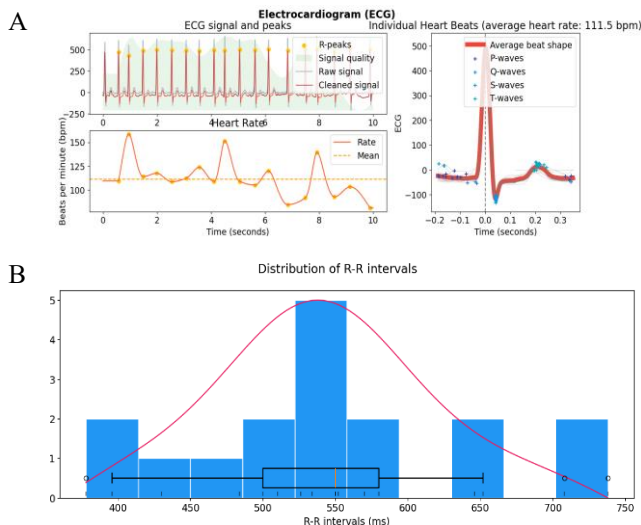


Figura 6: Resultados del minitutorial para el sujeto MUSE_20180119_173941_98000

Al aplicar la rutina de Neurokit se obtiene los resultados figura 4 donde el histograma y la curva de densidad ilustran la distribución de los intervalos R-R en milisegundos, proporcionando una visión clara de la variabilidad entre los tiempos de latidos consecutivos. La curva roja superpuesta modela la densidad de esta distribución, destacando la dispersión y concentración de los valores.

El boxplot, por su parte, representa la mediana, el rango intercuartílico y los valores atípicos de los intervalos R-R. En condiciones normales, estos intervalos suelen mostrar una distribución compacta, reflejando un ritmo cardíaco regular. Sin embargo, en el caso presentado, la amplitud de la distribución evidencia una variabilidad extrema, característica de la fibrilación auricular (AFIB).

Los valores atípicos, representados como puntos fuera del rango intercuartílico, subrayan aún más la irregularidad del ritmo, mostrando intervalos tanto más cortos como más largos de lo esperado. Además, la curva de

densidad revela múltiples picos, lo que podría estar asociado con diferentes patrones de conducción ventricular presente en pacientes con AFIB.

Los resultados de la figura 5 muestra la dispersión y concentración de los valores. El boxplot, por su parte, representa la mediana, el rango intercuartílico y los valores atípicos de los intervalos R-R. En condiciones normales, estos intervalos suelen mostrar una distribución compacta, reflejando un ritmo cardíaco regular. Sin embargo, en el caso presentado, la amplitud de la distribución evidencia una variabilidad extrema, característica de la fibrilación auricular (AFIB).

Los valores atípicos, representados como puntos fuera del rango intercuartílico, subrayan aún más la irregularidad del ritmo, mostrando intervalos tanto más cortos como más largos de lo esperado. Además, la curva de densidad revela múltiples picos, lo que podría estar asociado con diferentes patrones de conducción ventricular observados en pacientes con AFIB.

El histograma de la figura 6 ilustra la mediana, el rango intercuartílico y los valores atípicos, que se representan como puntos fuera de los bigotes. Este análisis revela una marcada variabilidad en los intervalos R-R, característica de la fibrilación auricular (AFIB).

La dispersión observada en el histograma y la presencia de valores atípicos refuerzan la irregularidad del ritmo cardíaco. Además, la amplia variación en la mediana y el rango intercuartílico refleja episodios significativos de intervalos tanto cortos como largos, subrayando la naturaleza errática de esta condición.

V. CARACTERÍSTICAS DE EXTRACCIÓN

La selección de estas características se fundamenta en su relevancia clínica y su capacidad para capturar variaciones significativas en las señales ECG, las cuales son indicativas de diversos estados fisiológicos y patológicos. Además, factores demográficos como el sexo y la edad son obligatorios, ya que permiten ajustar los modelos y garantizar su robustez y generalización en una población diversa. Estas características se agrupan en tres categorías principales. Las características básicas del ECG incluyen variables medidas y calculadas directamente a partir del electrocardiograma, que representan métricas estándar esenciales para identificar y clasificar arritmias mediante la detección de alteraciones específicas. Por su parte, los factores demográficos, como la edad y el sexo, son fundamentales para adaptar los modelos a las diferencias individuales, mejorando así su precisión y aplicabilidad en diversos contextos clínicos. Finalmente, las estadísticas adicionales derivadas del ECG comprenden medidas diseñadas para analizar la variabilidad y el comportamiento eléctrico del corazón, proporcionando

información detallada sobre su estado funcional. Esta integración permite un análisis completo de las señales ECG, optimizando la eficacia del modelo.

A. Ventricular rate in beats per minute (BPM)

La frecuencia ventricular, se mide en latidos por minuto (BPM), representa la cantidad de contracciones de los ventrículos por minuto y es una métrica clave para evaluar el ritmo cardíaco, identificando si este es normal, rápido o lento. Se calcula mediante el número de ondas QRS, que reflejan la contracción ventricular, registradas en un electrocardiograma (ECG). Una frecuencia normal oscila entre 60 y 100 BPM; valores inferiores a 60 BPM indican bradicardia, mientras que valores superiores a 100 BPM corresponden a taquicardia. Este parámetro es esencial para identificar ritmos como la bradicardia sinusal o la taquicardia supraventricular y para distinguir diversas arritmias relacionadas con la frecuencia cardíaca, proporcionando información fundamental para el diagnóstico y manejo de patologías cardiovasculares. [1]

B. Atrial rate in BPM (Frecuencia auricular en BPM)

Representa la cantidad de contracciones de las aurículas y se refleja en el electrocardiograma (ECG) mediante las ondas P. Se calcula contando el número de estas ondas en un intervalo de tiempo estándar. En condiciones normales, la frecuencia auricular suele ser similar a la frecuencia ventricular, pero en casos de arritmias, como la fibrilación auricular, las ondas P pueden estar ausentes o presentar irregularidades, lo que dificulta su medición. Este parámetro es crucial para diagnosticar arritmias auriculares como la fibrilación auricular o el flutter auricular, aportando información clave para el análisis y tratamiento de estas condiciones. [1]

C. Interval RR (Intervalo entre ondas R-R)

Es el tiempo que transcurre entre dos picos consecutivos de la onda R en un electrocardiograma (ECG), representando la duración de un ciclo cardíaco completo. Se mide en milisegundos (ms) y es fundamental para determinar la frecuencia cardíaca. Intervalos uniformes suelen ser indicativos de un ritmo sinusal normal, mientras que intervalos irregulares son característicos de condiciones como la fibrilación auricular o las arritmias sinusales. Este parámetro es especialmente importante porque proporciona información sobre la variabilidad del ritmo cardíaco, siendo una herramienta clave en la detección y análisis de arritmias. [4]

D. Edad y género

Son características demográficas fundamentales en la clasificación de señales ECG, ya que influyen

significativamente en las propiedades electrofisiológicas del corazón y en la prevalencia de ciertas condiciones cardíacas. El sexo afecta directamente los parámetros del ECG; por ejemplo, los hombres suelen presentar un intervalo QT más corto, mientras que las mujeres tienen un mayor riesgo de prolongación del QT inducida por medicamentos. Esta variable permite ajustar las predicciones y calibrar los modelos predictivos, reduciendo sesgos y mejorando la precisión del diagnóstico de arritmias específicas en cada género.

Por otro lado, la edad del paciente también es una variable crítica, ya que las características del ECG cambian con el envejecimiento. El intervalo QT tiende a prolongarse con la edad, y la prevalencia de arritmias como la fibrilación auricular aumenta en personas mayores. Considerar la edad en los modelos contribuye a un diagnóstico más preciso al reflejar cómo los riesgos cardíacos varían a lo largo de la vida. En conjunto estas características permiten un modelo más personalizado. [4]

E. QRS Count

El conteo de QRS se refiere al número de complejos QRS registrados en una señal de ECG dentro de un intervalo de tiempo específico. Este parámetro permite evaluar la frecuencia cardíaca, proporcionando información clave sobre la actividad eléctrica del corazón. Para determinar este conteo, se emplean algoritmos avanzados como el método de Pan-Tompkins o técnicas basadas en la Transformada Wavelet, que son altamente eficaces para detectar los picos R asociados a cada QRS. Posteriormente, los valores obtenidos se normalizan en latidos por minuto para facilitar su interpretación clínica. En el contexto de arritmias como la fibrilación auricular (AFIB) y la bradicardia sinusal (SB), el conteo de QRS adquiere un papel fundamental. En AFIB, la actividad auricular desorganizada provoca una variabilidad significativa en el número y el ritmo de los complejos QRS, reflejando una irregularidad en la conducción hacia los ventrículos. Por el contrario, en SB, el conteo de QRS se caracteriza por ser consistentemente bajo, evidenciando un ritmo cardíaco lento pero regular. Este parámetro es de gran utilidad clínica, ya que permite distinguir entre ritmos normales y patológicos, contribuyendo al diagnóstico de estas afecciones. [1]

F. QRS Duration

La duración del QRS es el tiempo que tarda en completarse el complejo QRS, reflejando la despolarización de los ventrículos. Este parámetro es crucial para evaluar la eficiencia de la conducción eléctrica ventricular. Su medición se realiza identificando el inicio y el final del complejo QRS mediante algoritmos avanzados que analizan bordes y

pendientes de la señal. Una vez detectados estos puntos, el intervalo de tiempo entre ellos se calcula en milisegundos, proporcionando una medida precisa de su duración. La importancia clínica de la duración del QRS radica en su capacidad para identificar patologías relacionadas con la conducción ventricular. En el contexto de arritmias como la fibrilación auricular (AFIB) y la bradicardia sinusal (SB), esta característica desempeña un papel fundamental. En AFIB, las variaciones en la duración del QRS pueden reflejar irregularidades en la conducción asociadas a un ritmo ventricular desorganizado. Por otro lado, en SB, la duración del QRS tiende a ser más uniforme, aunque el ritmo cardíaco es más lento. Para la clasificación de la duración del QRS, se emplean modelos supervisados de aprendizaje automático como máquinas de soporte vectorial (SVM) y árboles de decisión. Estos algoritmos permiten diferenciar entre duraciones normales y anómalas, facilitando la identificación de patrones asociados a distintas patologías cardíacas. [1]

G. TOffset

Es el punto final de la onda T en el electrocardiograma (ECG), que indica el final de la repolarización ventricular. Determinar el TOffset es esencial para medir el intervalo QT, que abarca desde el inicio del complejo QRS hasta el final de la onda T. Este intervalo es clave para evaluar el tiempo total de despolarización y repolarización ventricular, lo cual es fundamental en la detección de anomalías cardíacas. se puede determinar utilizando técnicas como, la transformada Wavelet para analizar los límites de la onda T o algoritmos que identifican los picos y finales de las ondas ECG. [2]

H. PhaseVentricular diastolic

La fase diastólica ventricular está relacionada de manera indirecta con varios segmentos del electrocardiograma, en especial con los intervalos RR y el segmento ST, que son clave para evaluar la relajación y recuperación ventricular. El intervalo RR ayuda a evaluar los tiempos de relajación, mientras que el segmento ST y el segmento TP están estrechamente vinculados con la recuperación ventricular. La clasificación de esta fase puede realizarse utilizando técnicas como el análisis de wavelet que pueden discriminar entre ritmos cardíacos que afectan la diástole, permitiendo identificar patrones relacionados con alteraciones en la fase de relajación ventricular. [2]

I. Phase ventricular systolic

Corresponde a la etapa del ciclo cardíaco en la que se produce la contracción ventricular. En un electrocardiograma (ECG), esta fase se refleja principalmente en el complejo QRS y el segmento ST. El complejo QRS representa la despolarización ventricular, marcando el inicio

de la contracción, mientras que el segmento ST muestra el intervalo entre la despolarización completa y el comienzo de la repolarización ventricular. Estos componentes son fundamentales para identificar posibles anomalías en la función ventricular, como arritmias o disfunciones miocárdicas, que pueden comprometer el funcionamiento del corazón. [3]

J. fMP

La fMP (frecuencia de máxima potencia) es el punto del espectro de frecuencia donde la señal ECG concentra su mayor potencia. Este parámetro, derivado del análisis espectral, proporciona información valiosa sobre la actividad rítmica dominante del corazón. Su importancia radica en que tanto la frecuencia cardíaca como las irregularidades del ritmo influyen directamente en la distribución de potencia en el dominio de la frecuencia. En el análisis de arritmias, la fMP es fundamental porque refleja cómo la actividad eléctrica del corazón se organiza en el dominio de la frecuencia. Por ejemplo, en casos de fibrilación auricular (AFIB), donde el ritmo auricular es desorganizado y el ritmo ventricular es irregular, el espectro de potencia suele mostrar múltiples frecuencias significativas, lo que hace que la fMP sea menos definida. Por el contrario, en casos de bradicardia sinusal (SB), la fMP es más clara y se asocia directamente con la frecuencia cardíaca dominante, lo que facilita su identificación. Esta característica permite una evaluación precisa de los patrones rítmicos y sugiere posibles alteraciones eléctricas en el corazón. [10]

VI. FLUJO DE TRABAJO

A. Extracción de características

Las características se calcularon a partir de los datos procesados de las señales de ECG de cada sujeto. Primero, se identificaron los picos R en la señal utilizando la información de los picos R, y a partir de ellos se calcularon los intervalos R-R mediante la función '`np.diff()`', considerando la frecuencia de muestreo de 500 Hz. La frecuencia ventricular promedio se obtuvo tomando el valor inverso de la media de los intervalos R-R, y luego multiplicando por 60 para convertirlo a latidos por minuto. En paralelo, se identificaron los picos P de la señal, limpiando los valores NaN y calculando la tasa atrial promedio a partir de la diferencia entre los picos P. El número total de complejos QRS se contabilizó contando los picos R detectados, mientras que el intervalo R-R promedio se calculó tomando la media de los intervalos R-R previamente calculados. Además, se utilizaron los valores de los tiempos de offset T para calcular su promedio, eliminando los valores NaN y considerando la frecuencia de muestreo. La fase ventricular se evaluó mediante la identificación de los períodos de sístole y diástole, contabilizando la cantidad de ciclos en cada fase.

Para completar los cálculos, se extrajo la información de frecuencia máxima de potencia (fMP) desde un conjunto de resultados preexistente del proyecto 2. Además, se buscaron datos del paciente, como la edad, el género y la duración del intervalo QRS, a partir de un archivo de información del paciente.

B. Rutina de extracción de características

La rutina de extracción de características se aplicó a un total de 5669 sujetos inicialmente seleccionados. Sin embargo, durante el proceso, se encontraron algunos inconvenientes que impidieron el procesamiento de 5 sujetos. Estos problemas surgieron debido a que ciertos sujetos no cumplían con el requisito mínimo de 5000 puntos de datos en sus señales, lo cual es necesario para asegurar la correcta evaluación y análisis. Además, algunos de estos sujetos presentaban dificultades en la detección de los picos R, lo que imposibilitó que la librería NeuroKit pudiera procesarlos adecuadamente. En el proceso de segmentación, también se detectaron valores NaN en los datos, lo que generó dificultades adicionales al momento de realizar el análisis, ya que estos valores no podían ser procesados. Como resultado, se logró procesar un total de 5664 sujetos, de los cuales se extrajeron diversas características relacionadas con la señal de ECG. Estos datos fueron organizados en un Dataframe que contiene las características de cada sujeto, como se puede observar en la Figura 7. Este DataFrame reúne información clave que será utilizada para los análisis posteriores en el estudio.

Filename	Rhythm	PatientAge	Gender	VentricularRate	AtrialRate	QRSCount	RRInterval	TORate	PhaseSystolic	PhaseDiastolic	QRSDuration
13_171127_27000	AFIB	85	MALE	117.000481	110.066499	19	0.512556	5.399647	1852	2860	114
12_073319_29000	SB	59	FEMALE	51.698671	51.660517	8	1.160571	5.500250	1467	2780	32
13_121940_44000	SB	66	MALE	53.309640	53.309640	9	1.125500	5.123000	1581	2522	36
12_120347_79000	SB	46	FEMALE	56.617127	56.590427	9	1.059750	5.030000	1564	2649	70
14_075026_69000	AFIB	80	FEMALE	95.703956	89.039644	16	0.626933	5.050400	2289	2414	74

Figura 7: Estructura del dataframe con extracción de características.

C. Arquitectura 1

El modelo de clasificación utilizado está basado en una red neuronal de perceptrón multicapa (MLP) con tres capas ocultas. La red tiene un total de 11 características de entrada, más una adicional para el sesgo, lo que da un total de 12 entradas para cada muestra de datos. La salida de la red es un único valor, que indica la clasificación entre dos posibles categorías: Bradicardia Sinusal (SB) o Fibrilación Auricular (AFIB).

El número de neuronas en cada capa oculta está determinado por el número total de muestras de datos (5664) y un factor de 3. El cálculo para determinar el número de neuronas en cada capa oculta es el siguiente:

$$\#Neu. = \frac{\text{Muestra total}}{\text{factor} (\#N \text{ entrada} + \#N \text{ salida})} \quad [1]$$

Esto resulta en 145 neuronas por capa oculta, lo que se aplica a las tres capas ocultas de la red neuronal.

El modelo utiliza la función de activación ReLU (Rectified Linear Unit) y el optimizador Adam para ajustar los pesos de la red. El número máximo de iteraciones para el entrenamiento es de 1000, lo que permite al modelo aprender de manera eficiente a lo largo de varias épocas.

D. Arquitectura 2

Como se mencionó anteriormente, el modelo de clasificación se basa en una red neuronal de perceptrón multicapa (MLP) con tres capas ocultas. En este caso, el número de neuronas en cada capa oculta se determina considerando un factor de 6, dando así el número de neuronas en cada capa oculta viene dado por la ecuación 1 y la suma de las neuronas de entrada (12) y salida (1). Esto resulta en 72 neuronas por capa oculta, lo que se aplica a las tres capas ocultas de la red neuronal.

E. Arquitectura 3

En este caso, el número de neuronas en cada capa oculta se determina considerando un factor de 9, dando así el número de neuronas en cada capa oculta viene dado por la ecuación 1 y la suma de las neuronas de entrada (12) y salida (1). Esto resulta en 48 neuronas por capa oculta, lo que se aplica a las tres capas ocultas de la red neuronal.

F. K-means

El algoritmo K-means es una técnica ampliamente utilizada en el análisis de señales ECG para agrupar ciclos cardíacos o latidos según sus características morfológicas o temporales. Su funcionamiento se basa en organizar los datos en grupos homogéneos, minimizando la variabilidad dentro de cada grupo. Las características extraídas del ECG, como la duración del complejo QRS, el intervalo RR o la amplitud de la onda T, se utilizan como puntos de entrada para el algoritmo.

El proceso comienza con la selección aleatoria de K centroides, que representan grupos iniciales de patrones cardíacos. Cada segmento o latido del ECG se asigna al cluster cuyo centroide esté más cercano, considerando métricas como la distancia euclidiana. Posteriormente, los centroides se actualizan calculando la media de las características de los puntos asignados a cada grupo. Este proceso de asignación y actualización se repite iterativamente hasta que los centroides convergen, es decir, permanecen estables, o se alcanza un número máximo de iteraciones.

Aplicando, K-means permite identificar patrones comunes entre latidos normales y anormales (arritmias), es una herramienta eficaz para segmentar grandes volúmenes de datos en estudios de monitoreo cardíaco. [3]

G. Máquina de soporte vectorial (SVM)

El algoritmo de Máquinas de Soporte Vectorial (SVM) es una herramienta para tareas de clasificación y agrupamiento, especialmente útil en el análisis de señales de electrocardiograma (ECG). Su objetivo es construir un modelo capaz de diferenciar latidos cardíacos normales de los anormales, basándose en un hiperplano óptimo que maximiza el margen de separación entre las categorías. Para lograrlo, las SVM extraen características relevantes de las señales ECG, como la duración del complejo QRS, el intervalo RR o la amplitud de la onda T, y las emplean como insumos para entrenar el modelo.

El funcionamiento del algoritmo se basa en proyectar los datos originales a un espacio de mayor dimensionalidad utilizando funciones kernel, como la gaussiana. Esta proyección es esencial para que datos que no son separables linealmente en su espacio original puedan dividirse con mayor precisión en el espacio transformado. Una vez en esta nueva representación, las SVM determinan el hiperplano que mejor separa las clases, optimizando la distancia entre los puntos más cercanos de cada categoría y este límite, conocidos como vectores de soporte. Además de la clasificación, las SVM pueden usarse para tareas de agrupamiento mediante su variante conocida como Support Vector Clustering (SVC). En este enfoque, el algoritmo utiliza los vectores de soporte para identificar contornos cerrados alrededor de las regiones densas de datos, agrupando señales que comparten características similares. Esto es particularmente útil para analizar señales ECG con formas de grupos complejas o no esferoidales, permitiendo la detección de patrones específicos incluso en situaciones de gran variabilidad entre individuos y condiciones patológicas.

El ajuste del algoritmo depende de parámetros clave como el ancho de la función kernel y el factor de regularización, los cuales controlan la sensibilidad a datos atípicos y el nivel de detalle en los contornos generados. Los resultados obtenidos pueden evaluarse con índices que miden la compactibilidad de los grupos y su separación, asegurando una partición de alta calidad. [4]

VII. DISCUSIÓN Y RESULTADOS

Se selecciono una relación 70/30 es decir, 70% de entrenamiento y 30% de prueba dando como resultado 3664 sujetos de entrenamiento y 1700 de prueba.

Para la arquitectura 1, donde se usaron 145 neuronas, se obtuvieron el siguiente reporte de clasificación:

A		precision	recall	f1-score	support
	SB	0.98	0.97	0.97	2696
	AFIB	0.94	0.95	0.94	1268
	accuracy			0.96	3964
	macro avg	0.96	0.96	0.96	3964
	weighted avg	0.96	0.96	0.96	3964
B		precision	recall	f1-score	support
	SB	0.97	0.96	0.97	1192
	AFIB	0.91	0.94	0.92	508
	accuracy			0.95	1700
	macro avg	0.94	0.95	0.94	1700
	weighted avg	0.95	0.95	0.95	1700

Figura 8: Reporte de clasificación para la arquitectura 1.

A. Entrenamiento B. Prueba

El reporte de clasificación muestra los resultados obtenidos utilizando un modelo con 145 neuronas en la capa oculta para un conjunto de datos de entrenamiento y prueba. En el conjunto de entrenamiento, el modelo logra una precisión promedio de 0.96, con una precisión de 0.98 para la clase SB (Bradicardia Sinusal) y 0.94 para la clase AFIB (Fibrilación Auricular). Los valores de recall son también elevados, alcanzando 0.97 para SB y 0.95 para AFIB, lo que indica que el modelo tiene un buen desempeño en la identificación de ambas clases. La métrica F1, que combina precisión y recall, también muestra un rendimiento sólido con 0.97 para SB y 0.94 para AFIB.

En el conjunto de prueba, el modelo mantiene un alto rendimiento con una precisión global de 0.95. Para la clase SB, la precisión es de 0.97 y el recall es de 0.96, lo que sugiere que el modelo sigue siendo efectivo en la clasificación de señales con bradicardia sinusal. Para AFIB, la precisión es de 0.91 y el recall es de 0.94, lo que muestra un buen desempeño, aunque ligeramente inferior en comparación con SB. La métrica F1 también refleja esta tendencia, con un valor de 0.97 para SB y 0.92 para AFIB.

Por otra parte, se obtuvieron las siguientes matrices de confusión:

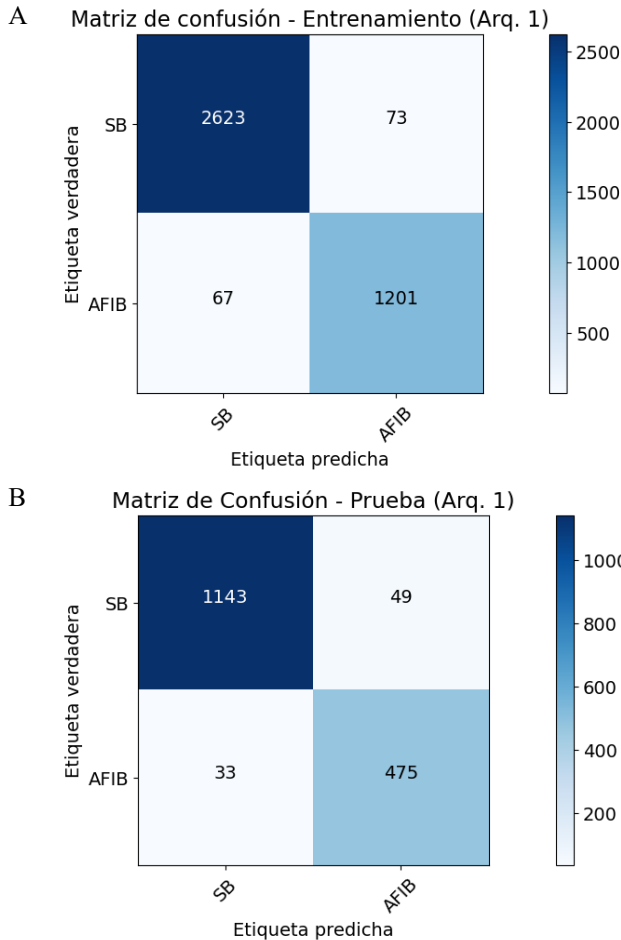


Figura 9: Matrices de confusión para la Arquitectura 1.

En el análisis de la matriz de confusión para el conjunto de entrenamiento y el conjunto de prueba, se pueden observar los valores de los verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos, lo que ayuda a evaluar el desempeño del modelo de manera más detallada.

Para el conjunto de entrenamiento, la matriz de confusión muestra que el modelo correctamente clasificó 2623 instancias como la clase SB (Bradicardia Sinusal) y 1201 instancias como la clase AFIB (Fibrilación Auricular). Sin embargo, también se cometieron algunos errores, con 73 instancias de SB clasificadas erróneamente como AFIB (falsos positivos) y 67 instancias de AFIB clasificadas erróneamente como SB (falsos negativos). Estos errores son relativamente pequeños en comparación con el número total de muestras, lo que refleja que el modelo tiene un buen desempeño en la clasificación.

En el conjunto de prueba, los valores también son bastante buenos. El modelo clasificó correctamente 1143 instancias como SB y 475 instancias como AFIB. En cuanto a los errores, 49 instancias de SB fueron clasificadas erróneamente como AFIB y 33 instancias de AFIB fueron

clasificadas erróneamente como SB. Aunque el número de errores es un poco mayor que en el conjunto de entrenamiento, los valores siguen siendo pequeños en comparación con el total de muestras, lo que indica que el modelo sigue funcionando de manera efectiva en el conjunto de prueba.

Al realizar la validación del modelo utilizando la técnica de K-fold cross-validation, se observó que la precisión promedio obtenida después de realizar 10 pliegues fue de 0.9511. Este valor indica que el modelo tiene un rendimiento sólido y consistente en diferentes particiones de los datos, lo que sugiere que es capaz de generalizar bien a nuevos datos no vistos.

Finalmente, al obtener la curva de pérdida de la arquitectura 1, se observa en la figura 10,




Figura 10: Curva de pérdida de la arquitectura 1

Al inicio del entrenamiento, la pérdida disminuye rápidamente. Esto indica que la red está aprendiendo rápidamente a capturar las relaciones básicas entre las características de entrada y las salidas deseadas. A medida que aumenta el número de iteraciones, la tasa de disminución de la pérdida se ralentiza y se estabiliza en un valor relativamente bajo. Esto sugiere que la red ha encontrado un buen ajuste a los datos de entrenamiento y ha dejado de mejorar significativamente.

Para la arquitectura 2, donde se tenían 72 neuronas en cada una de las capas ocultas, se encontró el siguiente reporte de clasificación:

A		precision	recall	f1-score	support
	SB	0.96	0.98	0.97	2696
	AFIB	0.95	0.92	0.93	1268
	accuracy			0.96	3964
	macro avg	0.96	0.95	0.95	3964
	weighted avg	0.96	0.96	0.96	3964

B		precision	recall	f1-score	support
	SB	0.97	0.96	0.97	1192
	AFIB	0.91	0.93	0.92	508
	accuracy			0.95	1700
	macro avg	0.94	0.94	0.94	1700
	weighted avg	0.95	0.95	0.95	1700

Figura 11: Reporte de clasificación para la arquitectura 2.

A. Entrenamiento B. Prueba

El reporte de clasificación para los datos de entrenamiento muestra un modelo con un rendimiento general bastante alto. Para la clase SB (Bradicardia Sinusal), la precisión es de 0.96, el recall es de 0.98 y el f1-score es de 0.97, lo que indica una excelente capacidad para identificar correctamente los casos de esta clase. Para la clase AFIB (Fibrilación Auricular), los valores de precisión, recall y f1-score son de 0.95, 0.92 y 0.93, respectivamente, lo que también refleja un buen rendimiento, aunque ligeramente inferior al de SB. La precisión total para el conjunto de entrenamiento es de 0.96, lo que refleja un modelo robusto que logra clasificar correctamente la mayoría de los datos.

En cuanto a los datos de prueba, el modelo sigue mostrando un rendimiento sólido, aunque con un leve descenso en la precisión comparado con los datos de entrenamiento. Para la clase SB, la precisión es de 0.97, el recall es de 0.96 y el f1-score es de 0.97, lo que indica que el modelo sigue siendo muy efectivo para esta clase en los datos no vistos. Sin embargo, para la clase AFIB, los valores de precisión, recall y f1-score son algo menores (0.91, 0.93 y 0.92, respectivamente), lo que sugiere que el modelo tiene un desempeño ligeramente inferior al clasificar los casos de fibrilación auricular en los datos de prueba.

La precisión global para el conjunto de prueba es de 0.95, lo que sigue siendo un valor alto, pero con una pequeña reducción respecto al conjunto de entrenamiento, lo cual es común cuando se evalúan modelos en datos no vistos. El promedio ponderado de las métricas de clasificación para los datos de prueba se mantiene en valores altos, lo que indica que el modelo es capaz de generalizar bien, aunque con un rendimiento ligeramente mejor para la clase SB que para la clase AFIB.

Por otra parte, se obtuvieron las siguientes matrices de confusión:





Figura 12: Matrices de confusión para la Arquitectura 2.

En el conjunto de entrenamiento, la matriz de confusión muestra que el modelo fue capaz de predecir correctamente 2632 instancias de Bradicardia Sinusal (SB), mientras que cometió 64 falsos positivos (es decir, predijo incorrectamente SB cuando en realidad era AFIB). Por otro lado, el modelo identificó correctamente 1169 casos de Fibrilación Auricular (AFIB), pero cometió 99 falsos negativos (es decir, no detectó correctamente AFIB cuando en realidad era AFIB). Estos valores indican que el modelo tiene una tasa de error relativamente baja en ambas clases, con más aciertos que errores.

En el conjunto de prueba, la matriz de confusión muestra que el modelo predijo correctamente 1147 casos de Bradicardia Sinusal (SB), con 45 falsos positivos. Para la clase de Fibrilación Auricular (AFIB), el modelo identificó correctamente 471 instancias, pero cometió 37 falsos negativos. Al igual que en el conjunto de entrenamiento, los errores son relativamente bajos en comparación con el número de aciertos.

La precisión promedio después de 10 folds es 0.9504, lo que indica que el modelo tiene un rendimiento generalmente alto en la clasificación de las dos clases (Bradicardia Sinusal y Fibrilación Auricular) cuando se evalúa mediante la validación cruzada con 10 particiones (folds).

El hecho de que la precisión promedio sea cercana al 0.95 refleja que el modelo es bastante confiable y consistente al clasificar tanto SB como AFIB en distintos subconjuntos de los datos. Dado que la validación cruzada ayuda a reducir el sesgo en la evaluación del modelo, este resultado refuerza la idea de que el modelo generaliza bien a diferentes muestras del conjunto de datos y no está sobreajustado a los datos de entrenamiento.

Finalmente, al obtener la curva de pérdida de la arquitectura 2, se observa en la figura 13 donde se evidencia que el modelo aprende rápidamente y después de aproximadamente 150 iteraciones esta pérdida converge.




Figura 13: Curva de pérdida de la arquitectura 2

Para la arquitectura 3, que tiene 48 neuronas se obtuvieron los siguientes reportes de clasificación:

A	Entrenamiento			
	precisión	recall	f1-score	support
SB	0.97	0.96	0.97	2696
AFIB	0.92	0.94	0.93	1268
accuracy			0.95	3964
macro avg	0.94	0.95	0.95	3964
weighted avg	0.95	0.95	0.95	3964

B	Prueba			
	precisión	recall	f1-score	support
SB	0.98	0.95	0.96	1192
AFIB	0.90	0.94	0.92	508
accuracy			0.95	1700
macro avg	0.94	0.95	0.94	1700
weighted avg	0.95	0.95	0.95	1700

Figura 14: Reporte de clasificación para la arquitectura 3.

A. Entrenamiento B. Prueba

En los datos de entrenamiento, el modelo presenta una precisión de 0.97 para la Bradicardia Sinusal (SB) y 0.92 para la Fibrilación Auricular (AFIB), lo que indica que el modelo tiene una mayor capacidad para identificar correctamente la clase SB en comparación con AFIB. El recall para SB es 0.96, lo que significa que el modelo es capaz de identificar correctamente el 96% de todas las instancias reales de SB. En contraste, el recall para AFIB es 0.94, mostrando que el modelo también tiene un buen rendimiento en la identificación de esta clase, aunque ligeramente inferior en comparación con SB. La precisión macro promedio de 0.94 y el f1-score macro promedio de 0.95 sugieren un buen balance en el desempeño del modelo para ambas clases.

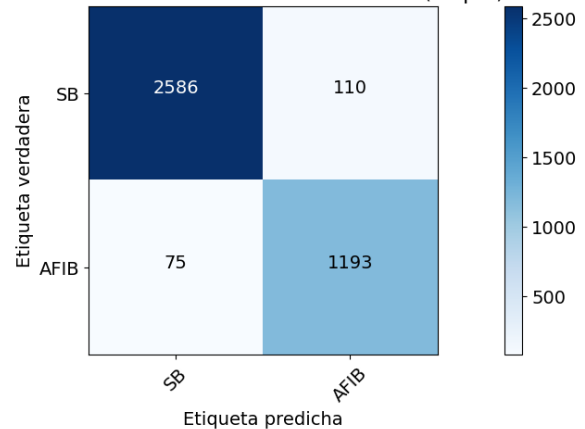
En cuanto a los datos de prueba, el modelo sigue mostrando un buen desempeño, con 0.98 de precisión para SB y 0.90 de precisión para AFIB. El recall para SB es 0.95, lo que implica que, aunque el modelo sigue siendo muy efectivo en la identificación de SB, hay una pequeña disminución en comparación con los datos de entrenamiento. Para AFIB, el recall es 0.94, lo que sugiere que el modelo mantiene una buena capacidad para detectar esta clase también en los datos de prueba.

El accuracy total en los datos de prueba es de 0.95, lo que indica que el modelo clasifica correctamente el 95%

de los casos en general. La precisión promedio ponderada es de 0.95, lo que también sugiere un buen desempeño global del modelo en ambas clases. Sin embargo, es importante destacar que, aunque el modelo tiene un buen rendimiento, las diferencias en los valores de precisión y recall entre las clases indican que hay un leve desbalance en cómo el modelo trata las dos clases, especialmente en cuanto a la identificación de AFIB.

Por otra parte, se obtuvieron las siguientes matrices de confusión:

A Matriz de confusión - Entrenamiento (Arq. 3)



B Matriz de Confusión - Prueba (Arq. 3)

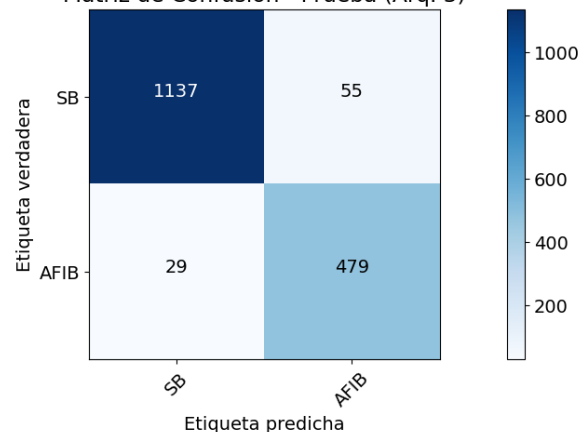


Figura 15: Matrices de confusión para la Arquitectura 3.

En el entrenamiento, la matriz de confusión muestra que el modelo clasificó correctamente 2586 instancias de Bradicardia Sinusal (SB) y 1193 instancias de Fibrilación Auricular (AFIB). Sin embargo, hubo 110 casos de SB clasificados incorrectamente como AFIB y 75 casos de AFIB clasificados incorrectamente como SB. Esto sugiere que el modelo tiene una ligera tendencia a confundir las dos clases, pero aun así mantiene un buen desempeño en términos de identificación correcta de ambas.

En los datos de prueba, el modelo mostró que 1137 instancias de SB fueron correctamente clasificadas, mientras

que 55 casos fueron incorrectamente clasificados como AFIB. Por otro lado, 479 casos de AFIB fueron correctamente identificados, pero 29 instancias de AFIB fueron clasificadas como SB. Esto indica que el modelo tiene un desempeño sólido en los datos de prueba, aunque nuevamente hay algunos errores de clasificación, particularmente con la clase AFIB.

La precisión promedio de 0.9495 obtenida después de realizar una validación cruzada de 10 folds sugiere que el modelo mantiene un rendimiento estable y confiable en distintos subconjuntos de los datos. Esta precisión indica que, en promedio, el modelo es capaz de clasificar correctamente aproximadamente el 94.95% de las instancias, lo cual es un desempeño notablemente alto. Además, dado que se trata de una validación cruzada, este valor también refleja que el modelo no depende en exceso de un conjunto específico de entrenamiento y tiene una capacidad de generalización adecuada, lo que es crucial para evitar el sobreajuste.

Finalmente, al obtener la curva de pérdida de la arquitectura 3, se observa en la figura 16:




Figura 16: Curva de pérdida de la arquitectura 3

Al analizar las tres arquitecturas propuestas para la clasificación de SB y AFIB, se observa que todas alcanzan un desempeño notable, con precisiones promedio cercanas al 95% en la validación por 10 folds. Sin embargo, se pueden destacar diferencias sutiles en su rendimiento y en la complejidad del modelo.

La arquitectura con 145 neuronas presenta la mayor precisión promedio, con un valor de 0.9511. Este modelo muestra un equilibrio robusto en las métricas de precisión, recall y f1-score tanto en los datos de entrenamiento como de prueba. En particular, su capacidad para clasificar correctamente instancias de SB y AFIB es consistente, como lo evidencian las matrices de confusión, donde los falsos positivos y falsos negativos son mínimos. Esto sugiere que esta arquitectura es altamente efectiva en captar patrones complejos en los datos.

La arquitectura con 72 neuronas obtiene una precisión promedio ligeramente inferior, de 0.9504, y mantiene un desempeño muy similar al de la arquitectura de 145 neuronas. Aunque utiliza menos neuronas, logra resultados comparables en todas las métricas, lo que indica que es un modelo más eficiente sin comprometer la calidad de la clasificación. Este equilibrio entre simplicidad y

rendimiento puede hacerla preferible en situaciones donde los recursos computacionales son limitados.

La arquitectura con 48 neuronas presenta la menor precisión promedio, con un valor de 0.9495, aunque la diferencia es mínima en comparación con las otras dos arquitecturas. Este modelo muestra un buen desempeño general, pero su capacidad para distinguir entre SB y AFIB es ligeramente menor, como se observa en un aumento marginal de los errores de clasificación en las matrices de confusión. Sin embargo, este modelo también tiene la ventaja de ser el más simple y liviano, lo que puede ser útil en aplicaciones donde se prioriza la velocidad o la eficiencia.

Por otro lado, se exploraron otros modelos de machine learning, como K-means y máquinas de soporte vectorial (SVM). En el caso de K-means, los reportes de clasificación obtenidos se presentan en la figura 17, mostrando los resultados específicos de este enfoque.

Reporte de clasificación usando K-means para los datos de entrenamiento				
	precision	recall	f1-score	support
SB	0.66	0.36	0.47	2696
AFIB	0.31	0.60	0.41	1268
accuracy			0.44	3964
macro avg	0.48	0.48	0.44	3964
weighted avg	0.55	0.44	0.45	3964
Reporte de clasificación usando K-means para los datos de prueba:				
	precision	recall	f1-score	support
SB	0.65	0.36	0.46	1192
AFIB	0.27	0.55	0.36	508
accuracy			0.42	1700
macro avg	0.46	0.45	0.41	1700
weighted avg	0.54	0.42	0.43	1700

Figura 17: Reporte de clasificación usando K-means para los datos de entrenamiento y los de prueba.

El análisis de los resultados obtenidos al aplicar el algoritmo K-means en la clasificación de latidos cardíacos revela varias limitaciones en su desempeño. En términos de precisión, el modelo muestra mejores resultados para la clase SB en comparación con AFIB. Esto indica que, cuando el modelo identifica un latido como SB, tiene más probabilidades de estar en lo correcto, pero presenta una alta tasa de error al clasificar AFIB, lo cual es crítico en aplicaciones médicas donde estas anomalías deben ser detectadas de forma confiable. En cuanto al recall, se observa que el modelo es más efectivo identificando correctamente latidos de fibrilación auricular que sinusales. Sin embargo, este mayor recall en AFIB no compensa las deficiencias en precisión, lo que se refleja en un F1-score bajo para ambas clases. Este indicador, que combina precisión y recall, pone de manifiesto un rendimiento limitado en el balance de estas métricas, particularmente en la identificación de fibrilación auricular, una condición que requiere diagnósticos precisos para evitar complicaciones.

El desempeño general del modelo, medido por la exactitud, es bajo, con valores de 44% en los datos de entrenamiento y 42% en los de prueba, lo que evidencia dificultades del modelo para generalizar correctamente. Además, los promedios macro y ponderado del F1-score refuerzan esta conclusión, indicando un bajo desempeño.

Ahora para el caso de maquinas de soporte vectorial (SVM) se obtiene los siguientes reportes de clasificación evidenciados en la figura 18.

Reporte de clasificación usando SVM para los datos de entrenamiento				
	precision	recall	f1-score	support
SB	0.86	0.98	0.92	2696
AFIB	0.94	0.66	0.78	1268
accuracy			0.88	3964
macro avg	0.90	0.82	0.85	3964
weighted avg	0.89	0.88	0.87	3964
Reporte de clasificación usando SVM para los datos de prueba:				
	precision	recall	f1-score	support
SB	0.88	0.97	0.92	1192
AFIB	0.91	0.70	0.79	588
accuracy			0.89	1780
macro avg	0.90	0.83	0.86	1780
weighted avg	0.89	0.89	0.88	1780

Figura 18: Reporte de clasificación usando SVM para los datos de entrenamiento y los de prueba.

En los datos de entrenamiento, el modelo muestra una precisión alta para la clase "SB" (0.86), indicando que es bastante preciso al identificar los casos negativos. Para la clase "AFIB", la precisión es aún mayor (0.94), lo que muestra que el modelo tiene menos falsos positivos al clasificar los casos de fibrilación auricular. Sin embargo, el recall para la clase "SB" es notablemente alto (0.98), lo que significa que el modelo identifica correctamente la mayoría de los casos negativos, mientras que para la clase "AFIB" el recall es más bajo (0.66), sugiriendo que el modelo tiene dificultades para identificar todos los casos positivos. El F1-score para "SB" es 0.92, reflejando un buen balance entre precisión y recall en esta clase, mientras que para "AFIB" es de 0.78, lo que indica un desempeño menos equilibrado.

La precisión general del modelo en los datos de entrenamiento es de 0.88, lo que indica un buen desempeño global, aunque con un rendimiento subóptimo en la clase "AFIB". Los promedios ponderados (0.89) y macro (0.90) sugieren un buen equilibrio en el rendimiento, especialmente en la clase "SB", que tiene más casos en el conjunto de datos. En los datos de prueba, la precisión para "SB" mejora ligeramente (0.88), mientras que la de "AFIB" disminuye ligeramente (0.91). El recall para "SB" aumenta a 0.97, lo que refleja una mayor capacidad del modelo para identificar correctamente los casos negativos en los datos de prueba. Sin embargo, el recall para "AFIB" sigue siendo relativamente

bajo (0.70), lo que indica que el modelo sigue teniendo dificultades para identificar correctamente los casos positivos en esta clase.

El F1-score para "SB" en los datos de prueba mejora a 0.92, y para "AFIB" se mantiene en 0.79, sugiriendo que el modelo sigue teniendo dificultades en obtener un buen equilibrio entre precisión y recall para esta clase. La precisión general en los datos de prueba es 0.89, lo que refleja un rendimiento similar al de los datos de entrenamiento. Los promedios ponderados y macro en los datos de prueba son 0.89 y 0.90, respectivamente, lo que sigue indicando un rendimiento equilibrado. Por tanto, el modelo SVM presenta un buen desempeño global, con una precisión alta, pero muestra un mayor desafío en la clasificación de la clase "AFIB", donde el recall y el F1-score son más bajos en comparación con "SB". Esto sugiere que el modelo podría beneficiarse de técnicas de balanceo de clases o ajustes en los parámetros de SVM para mejorar la detección de casos de fibrilación auricular.

La diferencia en la cantidad de sujetos por clase (3889 con SB frente a 1780 con AFIB) representa una limitación en el diseño y desempeño del modelo. Este desequilibrio en las clases puede haber influido en que los modelos de aprendizaje logran un mejor desempeño en la identificación de SB que de AFIB. Los modelos tienden a optimizar su precisión global al priorizar la predicción de la clase mayoritaria, lo que puede haber afectado la capacidad de generalización para la clase minoritaria (AFIB). Este sesgo en los datos subraya la necesidad de estrategias para abordar problemas de desbalance, como la ponderación de clases, el sobremuestreo de la clase minoritaria o el uso de métricas de evaluación específicas para cada clase.

VIII. ACTUALIDAD

A. Philips IntelliVue Patient Monitor.

Es un sistema avanzado diseñado para monitorear de manera integral y en tiempo real el estado de pacientes en entornos críticos, quirúrgicos, cardíacos, médicos y neonatales. Este equipo destaca por su capacidad para integrar algoritmos de ayuda diagnóstica, especialmente en la monitorización de señales ECG y el análisis de arritmias como fibrilación auricular (AFIB) y otras condiciones cardíacas.

El monitor incorpora algoritmos automáticos capaces de detectar y clasificar arritmias, monitorizando ritmos cardíacos irregulares mediante la identificación de patrones en el ECG, como intervalos RR, duración del QRS y el segmento ST. También emite alertas específicas para condiciones como AFIB, con notificaciones visuales y auditivas que permiten una rápida intervención. Además de su enfoque en la actividad cardíaca, el dispositivo admite la monitorización de múltiples parámetros fisiológicos, como

presión invasiva, saturación de oxígeno (SpO₂), frecuencia respiratoria y temperatura, con soporte para hasta 12 derivaciones de ECG, proporcionando un análisis detallado y preciso.

El equipo está diseñado para gestionar grandes cantidades de datos clínicos, almacenando tendencias, eventos críticos y cálculos relevantes, que pueden ser exportados o integrados en sistemas hospitalarios a través de redes locales, facilitando el acceso remoto a la información. Su interfaz intuitiva y configurable, con pantalla táctil, permite personalizar los perfiles de monitorización según las necesidades del paciente, mientras que herramientas adicionales como el ajuste de velocidad de las ondas y la congelación de señales apoyan el análisis detallado en tiempo real.

Una de sus características más destacadas son las alarmas inteligentes, que gestionan notificaciones basadas en condiciones críticas, reduciendo falsos positivos y ajustándose automáticamente según las condiciones del paciente. Esta combinación de detección avanzada, conectividad robusta y análisis en tiempo real convierte al Philips IntelliVue en una herramienta esencial para el manejo eficiente y confiable de pacientes críticos. [5]

B. GE Healthcare MAC 2000.

Es un sistema avanzado de análisis y adquisición de ECG portátil que integra algoritmos sofisticados de ayuda diagnóstica diseñados para interpretar señales ECG de forma eficiente y precisa. Este equipo es especialmente relevante en entornos clínicos y hospitalarios, destacándose por su capacidad para realizar análisis automatizados de 12 derivaciones de ECG y generar diagnósticos preliminares.

Entre los algoritmos incorporados, el MAC 2000 utiliza modelos avanzados para detectar y analizar características críticas como la duración del QRS, intervalos RR, frecuencia cardíaca y variaciones en el segmento ST. Estos algoritmos están optimizados para identificar patrones anómalos asociados a arritmias, como fibrilación auricular (AFIB) y trastornos de conducción. Una característica clave es su capacidad de clasificar automáticamente las señales en función de parámetros establecidos, ofreciendo alertas sobre posibles condiciones patológicas y generando informes interpretativos detallados.

El equipo también emplea algoritmos de corrección para eliminar artefactos y ruido en las señales, asegurando que el análisis sea preciso incluso en condiciones menos ideales. Los datos analizados se integran en algoritmos interpretativos que destacan por su alta sensibilidad y especificidad, ayudando a los médicos a tomar decisiones clínicas más rápidas y fundamentadas.

Además, el MAC 2000 está diseñado para conectividad avanzada, lo que permite transmitir datos

procesados a sistemas de información cardiovascular. Esto no solo mejora la eficiencia del flujo de trabajo, sino que también permite que los algoritmos aprendan y se ajusten a través de actualizaciones continuas, fortaleciendo su capacidad diagnóstica.

Este enfoque basado en algoritmos avanzados no solo facilita la detección temprana de anomalías cardíacas, sino que también respalda un diagnóstico preciso, optimizando la atención al paciente y reduciendo los márgenes de error en la interpretación manual. [6]

C. Philips ST80i Stress Test System.

Es un sistema diseñado para realizar pruebas de esfuerzo con algoritmos avanzados que analizan señales ECG en tiempo real. Este equipo emplea el algoritmo DXL para interpretar datos electrocardiográficos, proporcionando análisis detallados de hasta 16 derivaciones. Su funcionalidad incluye la detección de arritmias, el monitoreo de segmentos ST y la evaluación de la frecuencia cardíaca en diferentes fases de la prueba.

Entre sus características más destacadas, el ST80i utiliza el algoritmo CAlg-STR para analizar cambios específicos durante las pruebas de esfuerzo, incluyendo patrones en el segmento ST y alteraciones de la frecuencia cardíaca, ayudando a identificar anomalías cardíacas inducidas por el ejercicio. El equipo también incorpora herramientas de filtro para reducir el ruido en las señales, mejorando la precisión del análisis.

El sistema permite generar reportes detallados, incluyendo tendencias, valores promedios y eventos críticos detectados, lo que facilita la toma de decisiones clínicas rápidas. Además, su conectividad inalámbrica y su diseño intuitivo optimizan el flujo de trabajo, garantizando seguridad y comodidad tanto para el paciente como para el personal médico. [7]

IX. CONCLUSIONES

- Las arquitecturas de redes neuronales artificiales demostraron ser altamente efectivas para la clasificación automática de bradicardia sinusal (SB) y fibrilación auricular (AFIB), alcanzando precisiones globales superiores al 95%. En particular, la configuración 1 con 145 neuronas en las capas ocultas ofreció un desempeño ligeramente mejor, destacándose como la arquitectura más adecuada para este propósito.
- El desbalance de clases, con una mayor proporción de sujetos con SB en comparación con AFIB, limitó la capacidad de los modelos para generalizar de manera uniforme entre ambas clases. Este hallazgo subraya la importancia de ajustar el conjunto de datos o emplear técnicas específicas para manejar desequilibrios en problemas de clasificación médica.

- Las características extraídas de las señales de ECG, como el ritmo ventricular, el intervalo RR y los eventos asociados con las fases cardíacas, demostraron ser determinantes para el rendimiento del modelo. Este resultado destaca la importancia crucial de un procesamiento previo riguroso y la selección óptima de características haciendo uso de herramientas como NeuroKit en proyectos de análisis de señales biomédicas, dado su impacto directo en la precisión y confiabilidad del modelo.

REFERENCIAS

- [1] Zheng, J., Chu, H., Struppa, D., Zhang, J., Yacoub, S. M., El-Askary, H., ... & Rakovski, C. (2020). Optimal multi-stage arrhythmia classification approach. *Scientific reports*, 10(1), 2898. <https://www.nature.com/articles/s41598-020-59821-7#Sec4>
- [2] Villazana, S., Arteaga, F., Seijas, C., & Rodriguez, O. (2012). Estudio comparativo entre algoritmos de agrupamiento basado en svm y c-medios difuso aplicados a señales electrocardiográficas arritmicas. *Revista Ingeniería UC*, 19(1), 16-24. <https://www.redalyc.org/pdf/707/70732261003.pdf>
- [3] Materko, W., Bartels, R., Carvalho, A. R. S., & Nadal, J. ESTRATIFICAÇÃO DA APTIDÃO AERÓBIA A PARTIR DA VARIABILIDADE DA FREQUÊNCIA DE REPOUSO PELA ANÁLISE DE COMPONENTES PRINCIPAIS E AGRUPAMENTO POR K-MEANS. https://www.canal6.com.br/cbeb/2014/artigos/cbeb2014_submissio_n_749.pdf
- [4] Bishop, C. M. (2006). Pattern recognition and machine learning. Springer google schola, 2, 1122-1128. chrome-extension://efaidnbmnnnibpcajpcgglefindmkaj/https://www.papiro-bookstore.com/wp-content/uploads/2021/12/Pattern-Recognition-and-Machine-Learning.pdf
- [5] Philips Healthcare. (n.d.). IntelliVue Patient Monitor MX400/MX450/MX500/MX550/MX600/MX700/MX800: Instructions for Use. Philips Healthcare. chrome-extension://efaidnbmnnnibpcajpcgglefindmkaj/https://medaval.ie/docs/manuals/Intellivue-Manual.pdf
- [6] Sheet, S. MACTM 2000. <https://quincemedical.com/wp-content/uploads/2023/05/GE-MAC-2000-Specification-Sheet.pdf>
- [7] Philips Healthcare. (n.d.). ST80i Stress Test System - Instructions for Use. Philips Healthcare. <https://fcc.report/FCC-ID/PQC-AIM/7248121.pdf>